

Matriz de costos por modelo y tarea

Ecosistema de Automatizacion IA Autonomo · NubeFlow Consulting (caso de uso) · n8n + Airtable + Claude + Gmail

Tarifas oficiales de Anthropic (consultadas el 21-sep-2026, USD por millon de tokens): **Haiku 4.5** \$1 entrada / \$5 salida; **Sonnet 5** \$2 / \$10; **Opus 5** \$5 / \$25. Batch API: 50 % de descuento, pero no aplica aqui porque el flujo es en tiempo real.

1. Costo por llamada, por tarea y modelo

Tarea	Modelo	Tokens entrada	Tokens salida	Costo por llamada	Origen de los tokens
T1 Relevancia + extraccion (todo correo entrante)	Haiku 4.5	700	150	\$0.00145	estimado
T1 Relevancia + extraccion (todo correo entrante)	Sonnet 5	700	150	\$0.00290	estimado
T1 Relevancia + extraccion (todo correo entrante)	Opus 5	700	150	\$0.00725	estimado
T2 Scoring cualitativo (correos relevantes)	Haiku 4.5	317	315	\$0.00189	medido (ejecucion 15)
T2 Scoring cualitativo (correos relevantes)	Sonnet 5	317	315	\$0.00378	medido (ejecucion 15)
T2 Scoring cualitativo (correos relevantes)	Opus 5	317	315	\$0.00946	medido (ejecucion 15)
T3 Borrador de email (solo VIP)	Haiku 4.5	250	350	\$0.00200	estimado
T3 Borrador de email (solo VIP)	Sonnet 5	250	350	\$0.00400	estimado
T3 Borrador de email (solo VIP)	Opus 5	250	350	\$0.01000	estimado

Solo T2 esta medido: 317 tokens de entrada y 315 de salida en una ejecucion real (ID 15), lo que costo \$0.001892 con Haiku; ese dato coincide con el campo Costo_IA_microUSD = 1892 de Airtable. T1 y T3 son estimaciones a partir del largo de los prompts; hay que reemplazarlas con datos reales cuando se registren sus tokens (ver limitaciones).

2. Costo mensual por escenario de asignacion de modelos

Supuestos del embudo: de cada 100 correos entrantes, **30 son consultas relevantes** y, de esas, **15 % son VIP** (4,5 de cada 100). Cada correo pasa por T1; solo los relevantes por T2; solo los VIP por T3.

Escenario	100 correos/mes	500	1.000	5.000	Por lead relevante
A. Diseno actual (Haiku filtro/scoring + Sonnet borrador)	\$0.22	\$1.10	\$2.20	\$10.99	\$0.0073
B. Todo Haiku 4.5	\$0.21	\$1.05	\$2.11	\$10.54	\$0.0070
C. Todo Sonnet 5	\$0.42	\$2.11	\$4.22	\$21.08	\$0.0141

D. Todo Opus 5	\$1.05	\$5.27	\$10.54	\$52.69	\$0.0351
----------------	--------	--------	---------	---------	----------

3. Lectura y decision

Recomendado: escenario A. El filtro y el scoring son tareas de clasificacion con salida corta, donde Haiku 4.5 basta y cuesta 5 veces menos que Opus 5. Sonnet 5 se reserva para el borrador que un ejecutivo leera antes de aprobar, donde la calidad de redaccion importa y solo se usa para los VIP.

- Con 1.000 correos al mes el diseno actual cuesta del orden de **un dolar**: la IA no es el costo relevante del proyecto.
- El mayor ahorro no es cambiar de modelo sino **filtrar antes**: T1 es la unica llamada que corre sobre todo el correo entrante, por eso usa el modelo mas barato y un limite de 3.000 caracteres del cuerpo.
- Subir todo a Sonnet 5 duplica el costo sin mejora esperable en clasificacion; Opus 5 lo multiplica por cinco.

4. Cache de prompts y Batch

No se cuentan ahorros por cache: los prompts del sistema tienen unos pocos cientos de tokens, muy por debajo del minimo cacheable, por lo que un `cache_control` no tendria efecto. Batch API (-50 %) solo serviria para un reproceso masivo historico, no para el flujo en tiempo real.

5. Limitaciones y proximos pasos

- Airtable registra los tokens solo de T2. Para tener el costo real completo por lead hay que guardar tambien los tokens de T1 y T3 (dos campos mas y dos asignaciones en n8n).
- Las tarifas estan escritas en la formula `Costo_IA_microUSD` (1 y 5 micro-USD por token); si cambian o se usa otro modelo, hay que actualizarla.
- El umbral VIP (80) y las proporciones del embudo son supuestos; se ajustan con los datos de las primeras semanas.
- Otros costos fuera de la matriz: n8n Cloud (segun plan), Airtable (segun plan) y Gmail (sin costo directo).

Datos en CSV: `docs/matriz_costos.csv` y `docs/matriz_costos_escenarios.csv`.